

摩尔线程 Torch_MUSA 开发者手册

版本 0.1.0

2024年01月04日



717
316
7

目	目录 ·				
1	版权	声明	1		
2	前言		2		
	2.1	版本记录	2		
	2.2	更新历史	2		
3	简介		3		
	3.1	MUSA 概述	3		
	3.2	PyTorch 概述	3		
	3.3	torch_musa 概述	3		
	3.4	torch_musa 核心代码目录概述	4		
4	编译		5		
	4.1	依赖环境	5		
	4.2	编译流程	5		
	4.3	开发 Docker	6		
	4.4	编译步骤	6		
		4.4.1 设置环境变量	6		
		4.4.2 使用脚本一键编译(推荐)	6		
		4.4.3 分步骤编译	7		
5	快速.	λ门	8		
	5.1	常用环境变量	8		
	5.2	常用 api 示例代码	8		
	5.3	推理示例代码	9		
	5.4	训练示例代码	9		
	5.5	C++ 部署示例代码	12		
6	算子	支持	13		
	6.1	何时需要适配新算子?	13		
	6.2	如何适配新算子	13		
		6.2.1 先注册新算子			
		6.2.2 利用 MUDNN 实现算子	15		
		6.2.3 利用 CUDA-Porting 实现算子			
		6.2.3.1 以 abs 算子为例	17		

		6.2.3.2 以 tril 算子为例	18			
		6.2.4 利用 CPU 实现算子	21			
		6.2.5 添加算子单元测试	21			
		6.2.6 即将支持的特性	21			
7	自定	义算子支持 22				
	7.1	支持自定义算子	22			
8	第三	方库 MUSA 扩展支持	23			
	8.1	为什么要对第三方库进行 MUSA 扩展的构建?	23			
	8.2	如何对第三方库进行 MUSA 扩展?	24			
		8.2.1 了解 MUSAExtension 这个 API	24			
		8.2.2 CUDA-Porting	24			
		8.2.3 分析 mmcv 的构建脚本 setup.py	26			
		8.2.4 尝试构建并测试	28			
9	调试	【工具 33				
	9.1	CompareTool 使用指南	33			
		9.1.1 基本用法	33			
		9.1.2 输出示例	33			
		9.1.3 错误追踪与调试	36			
10	FAQ		38			
	10.1	设备查看问题	38			
	10.2	计算库无法找到	38			
	10.3	3 编译安装				
	10.4	Docker 容器	39			
	10.5	适配算子	39			



1版权声明

版权章节待完善。

- 版权声明
- © 2023



2前言

2.1 版本记录

表 2.1: 版本记录

文档名称	摩尔线程 Torch_MUSA 开发者手册	
版本号	V 0.1.0	
作者 Moore Threads		
修改日期	2024年01月04日	

2.2 更新历史

• V0.1.0

更新时间: 2023.05.29

更新内容:

- 完成初版 Torch_MUSA 开发者手册。



3简介

3.1 MUSA 概述

MUSA (Metaverse Unified System Architecture) 是摩尔线程公司为摩尔线程 GPU 推出的一种通用并行计算平台和编程模型。它提供了 GPU 编程的简易接口,用 MUSA 编程可以构建基于 GPU 计算的应用程序,利用 GPUs 的并行计算引擎来更加高效地解决比较复杂的计算难题。同时摩尔线程还推出了MUSA 工具箱(MUSAToolkits),工具箱中包括 GPU 加速库,运行时库,编译器,调试和优化工具等。MUSAToolkits 为开发人员在摩尔线程 GPU 上开发和部署高性能异构计算程序提供软件环境。

关于 MUSA 软件栈的更多内容,请参见 MUSA 官方文档。

3.2 PyTorch 概述

PyTorch 是一款开源的深度学习编程框架,可以用于计算机视觉,自然语言处理,语音处理等领域。 PyTorch 使用动态计算,这在构建复杂架构时提供了更大的灵活性。PyTorch 使用核心 Python 概念,如 类、结构和条件循环,因此理解起来更直观,编程更容易。此外,PyTorch 还具有可以轻松扩展、快速 实现、生产部署稳定性强等优点。

关于 PyTorch 的更多内容,请参见 PyTorch 官方文档。

3.3 torch_musa 概述

为了摩尔线程 GPU 能支持开源框架 PyTorch,摩尔线程公司开发了 torch_musa。在 PyTorch v2.0.0 基础上,torch_musa 以插件的形式来支持摩尔线程 GPU,最大程度与 PyTorch 代码解耦,便于代码维护与升级。torch_musa 利用 PyTorch 提供的第三方后端扩展接口,将摩尔线程高性能计算库动态注册到 PyTorch 上,从而使得 PyTorch 框架能够利用摩尔线程显卡的高性能计算单元。利用摩尔线程显卡 CUDA 兼容的特性,torch_musa 内部引入了 cuda 兼容模块,使得 PyTorch 社区的 CUDA kernels 经过 porting 后就可以运行在摩尔线程显卡上,而且 CUDA Porting 的工作是在编译 torch_musa 的过程中自动进行,这大幅降低了 torch_musa 算子适配的成本,提高模型开发效率。同时,torch_musa 在 Python 前端接口与 PyTorch 社区 CUDA 接口形式上基本保持一致,这极大地降低了用户的学习成本和模型的迁移成本。

本手册主要介绍了基于 MUSA 软件栈的 torch musa 开发指南。

3.4 torch_musa 核心代码目录概述

- torch_musa/tests 测试文件
- torch_musa/core 主要包含 Python module,提供 Python 前端的接口。
- torch_musa/csrc c++ 侧实现代码
 - csrc/aten 提供 C++ Tensor 库,包括 MUDNN 算子适配,CUDA-Porting 算子适配等等
 - csrc/core 提供核心功能库,包括设备管理,内存分配管理,Stream 管理,Events 管理等



4编译安装

注意:

编译安装前,需要安装 MUSAToolkits 软件包,MUDNN 库,muThrust 库,muAlg 库,muRAND 库,muSPARSE 库。具体安装步骤,请参见相应组件的安装手册。

4.1 依赖环境

- Python == 3.8 或者 Python == 3.9。
- 摩尔线程 MUSA 软件包,推荐版本如下:
 - MUSA 驱动 rc1.4.1
 - MUSAToolkits Release1.4.1
 - MUDNN rc1.4.1
 - muAlg_dev-0.1.1-Linux.deb
 - muRAND_dev1.0.0.tar.gz
 - muSPARSE_dev0.1.0.tar.gz
 - muThrust_dev-0.1.1-Linux.deb
 - Docker Container Toolkits(https://mcconline.mthreads.com/software)

4.2 编译流程

- 1. 向 PyTorch 源码打 patch
- 2. 编译 PyTorch
- 3. 编译 torch_musa

torch_musa 是在 PyTorch v2.0.0 基础上以插件的方式来支持摩尔线程显卡。开发时涉及到对 PyTorch 源码的修改,目前是以打 patch 的方式实现的。PyTorch 社区正在积极支持第三方后端接入,https://github.com/pytorch/pytorch/issues/98406 这个 issue 下有相关 PR。我们也在积极向 PyTorch 社区提交 PR,避免在编译过程中向 PyTorch 打 patch。

4. 编译安装 4.3. 开发 DOCKER

4.3 开发 Docker

为了方便开发者开发 torch_musa,我们提供了开发用的 docker image,参考命令:

```
docker run -it --name=torch_musa_dev --env MTHREADS_VISIBLE_DEVICES=all --shm-size=80g sh-
harbor.mthreads.com/mt-ai/musa-pytorch-dev:latest /bin/bash
```

注意:

使用 docker 时,请务必提前安装 mt-container-toolkit(https://mcconline.mthreads.com/software/1?id=1),并且在启动 docker container 时添加选项 "--env MTHREADS_VISIBLE_DEVICES=all",否则在 docker container 内部无法使用 torch_musa。

4.4 编译步骤

4.4.1 设置环境变量

```
export MUSA_HOME=path/to/musa_libraries(including musa_toolkits, mudnn and so on) # defalut_\(\text{u}\) \(\text{oral/musa/}\)
export LD_LIBRARY_PATH=$MUSA_HOME/lib:$LD_LIBRARY_PATH
export PYTORCH_REPO_PATH=path/to/PyTorch source code
# if PYTORCH_REPO_PATH is not set, PyTorch-v2.0.0 will be downloaded outside this directory_\(\text{u}\) \(\text{automatically when building with build.sh}\)
```

4.4.2 使用脚本一键编译(推荐)

```
cd torch_musa
bash docker/common/daily/update_daily_mudnn.sh # update daily mudnn lib if needed
bash build.sh # build original PyTorch and torch_musa from scratch

# Some important parameters are as follows:
bash build.sh --torch # build original PyTorch only
bash build.sh --musa # build torch_musa only
bash build.sh --fp64 # compile fp64 in kernels using mcc in torch_musa
bash build.sh --debug # build in debug mode
bash build.sh --asan # build in asan mode
bash build.sh --clean # clean everything built
```

4. 编译安装 4.4. 编译步骤

在初次编译时,需要执行 bash build.sh(先编译 PyTorch,再编译 torch_musa)。在后续开发过程中,如果不涉及对 PyTorch 源码的修改,那么执行 bash build.sh -m(仅编译 torch_musa)即可。

4.4.3 分步骤编译

如果不想使用脚本编译,那么可以按照如下步骤逐步编译。

1. 在 PyTorch 打 patch

```
# 请保证 PyTorch 源码和 torch_musa 源码在同级目录或者 export PYTORCH_REPO_PATH=path/to/PyTorch 指向 PyTorch 源码
bash build.sh --only-patch
```

2. 编译 PyTorch

```
cd pytorch
pip install -r requirements.txt

python setup.py install
# debug mode: DEBUG=1 python setup.py install
# asan mode: USE_ASAN=1 python setup.py install
```

3. 编译 torch musa

```
cd torch_musa
pip install -r requirements.txt
python setup.py install
# debug mode: DEBUG=1 python setup.py install
# asan mode: USE_ASAN=1 python setup.py install
```



5快速入门

注解:

使用 torch_musa 时,需要先导入 torch 包(import torch)和 torch_musa 包 (import torch_musa)。

5.1 常用环境变量

开发 torch_musa 过程中常用环境变量如下表所示:

环境变量示例	所属组件	功能说明
export MUDNN_LOG_LEVEL=INFO	MUDNN	使能 MUDNN 算子库调用的 log
export MUSA_VISIBLE_DEVICES=0,1,2,3	Driver	控制当前可见的显卡序号
export MUSA_LAUNCH_BLOCKING=1	Driver	驱动以同步模式下发 kernel,即当 前 kernel 执行结束后再下发下一个 kernel

表 5.1: 常用环境变量

5.2 常用 api 示例代码

```
import torch
import torch_musa

torch.musa.is_available()
torch.musa.device_count()

a = torch.tensor([1.2, 2.3], dtype=torch.float32, device='musa')
b = torch.tensor([1.8, 1.2], dtype=torch.float32, device='musa')
c = a + b

torch.musa.synchronize()
```

5. 快速入门 5.3. 推理示例代码

```
with torch.musa.device(0):
    assert torch.musa.current_device() == 0

if torch.musa.device_count() > 1:
    torch.musa.set_device(1)
    assert torch.musa.current_device() == 1
    torch.musa.synchronize("musa:1")
```

torch_musa 中 python api 基本与 PyTorch 原生 api 接口保持一致,极大降低了新用户的学习成本。

5.3 推理示例代码

```
import torch
import torch_musa
import torchvision.models as models

model = models.resnet50().eval()
x = torch.rand((1, 3, 224, 224), device="musa")
model = model.to("musa")

# Perform the inference
y = model(x)
```

5.4 训练示例代码

5. 快速入门 5.4. 训练示例代码

```
download=True, transform=transform)
trainloader = torch.utils.data.DataLoader(trainset, batch_size=batch_size,
                                          shuffle=True, num_workers=2)
testset = torchvision.datasets.CIFAR10(root='./data', train=False,
                                       download=True, transform=transform)
testloader = torch.utils.data.DataLoader(testset, batch_size=batch_size,
                                         shuffle=False, num_workers=2)
classes = ('plane', 'car', 'bird', 'cat',
           'deer', 'dog', 'frog', 'horse', 'ship', 'truck')
device = torch.device("musa")
## 2. build network
class Net(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 6, 5)
        self.pool = nn.MaxPool2d(2, 2)
        self.conv2 = nn.Conv2d(6, 16, 5)
        self.fc1 = nn.Linear(16 * 5 * 5, 120)
        self.fc2 = nn.Linear(120, 84)
        self.fc3 = nn.Linear(84, 10)
    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = torch.flatten(x, 1) # flatten all dimensions except batch
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x
net = Net().to(device)
## 3. define loss and optimizer
criterion = nn.CrossEntropyLoss()
optimizer = optim.SGD(net.parameters(), lr=0.001, momentum=0.9)
## 4. train
for epoch in range(2): # loop over the dataset multiple times
   running_loss = 0.0
    for i, data in enumerate(trainloader, 0):
        # get the inputs; data is a list of [inputs, labels]
```

5. 快速入门 5.4. 训练示例代码

```
inputs, labels = data
        # zero the parameter gradients
        optimizer.zero_grad()
        # forward + backward + optimize
        outputs = net(inputs.to(device))
        loss = criterion(outputs, labels.to(device))
        loss.backward()
        optimizer.step()
        # print statistics
        running_loss += loss.item()
        if i % 2000 == 1999:
                               # print every 2000 mini-batches
            print(f'[{epoch + 1}, {i + 1:5d}] loss: {running_loss / 2000:.3f}')
            running_loss = 0.0
print('Finished Training')
PATH = './cifar_net.pth'
torch.save(net.state_dict(), PATH)
net.load_state_dict(torch.load(PATH))
## 5. test
correct = 0
total = 0
# since we're not training, we don't need to calculate the gradients for our outputs
with torch.no_grad():
    for data in testloader:
        images, labels = data
        # calculate outputs by running images through the network
        outputs = net(images.to(device))
        # the class with the highest energy is what we choose as prediction
        _, predicted = torch.max(outputs.data, 1)
        total += labels.size(0)
        correct += (predicted == labels.to(device)).sum().item()
print(f'Accuracy of the network on the 10000 test images: {100 * correct // total} %')
```

5. 快速入门 5.5. C++ 部署示例代码

5.5 C++ 部署示例代码

```
#include <torch/script.h>
#include <torch_musa/csrc/core/Device.h>
#include <iostream>
#include <memory>
int main(int argc, const char* argv[]) {
 // Register 'musa' for PrivateUse1 as we save model with 'musa'.
 c10::register_privateuse1_backend("musa");
 torch::jit::script::Module module;
 // Load model which saved with torch jit.trace or jit.script.
 module = torch::jit::load(argv[1]);
  std::vector<torch::jit::IValue> inputs;
  // Ready for input data.
  torch::Tensor input = torch::rand({1, 3, 224, 224}).to("musa");
  inputs.push_back(input);
 // Model execute.
 at::Tensor output = module.forward(inputs).toTensor();
 return 0;
```

详细用法请参考 examples/cpp1 下内容。

 $^{^1\} https://github.mthreads.com/mthreads/torch_musa/tree/main/examples/cpp$



6算子支持

本节主要介绍如何在 torch_musa 中适配一个新算子,算子实现后端包括 MUDNN 算子库和 CUDA-Porting kernels。

6.1 何时需要适配新算子?

以"tril"算子为例,当我们的测试代码有如下报错 log,则说明 torch_musa 中没有适配"tril"算子。

```
import torch
import torch_musa
input_data = torch.randn(3, 3, device="musa")
result = torch.tril(input_data)
```

```
Traceback (most recent call last):
    File "test.py", line 5, in emodule>
        result = torch.tril(input data)

MutImplementedError: Could not run 'aten::tril.out' with arguments from the 'musa' backend] This could be because the operator doesn't exist for this backend, or was omitted during the selective/custom build process (if using custom build). If you are a Facebook employee using PyTorch on mobile, please visit https://fburl.com/ptmfixes for possible resolutions. 'aten: tril.out' is only available for these backends: [CPV, Meta, BackendSelect, Python, FuncTorchDynamicLayerBackWode, Functionalize, Named, Conjugate, Negative, ZeroPersor, AlDinJaceOrView, AutogradOther, AutogradCPU, Autogra
```

6.2 如何适配新算子

6.2.1 先注册新算子

算子实现的注册可以参考 PyTorch 官方文档 https://pytorch.org/tutorials/advanced/dispatcher.html ,也可以参考 PyTorch 框架中 CUDA 后端的注册代码。在编译完 PyTorch 代码后会生成下图中的文件,PyTorch 在该文件中实现了 CUDA 后端实现的注册。

```
MILLHIPL( DILWISE LEIL SHILLLENSOF OUL , TOKCH FN(WEAPPER CODA DILWISE LEIL SHILL OUL TE
m.impl("bitwise left shift .Tensor", TORCH FN(wrapper CUDA bitwise left shift Tensor))
m.impl(" rshift .Scalar",
TORCH FN(wrapper CUDA Scalar rshift ));
m.impl(" irshift .Scalar",
TORCH FN(wrapper CUDA Scalar irshift ));
m.impl(" rshift .Tensor",
TORCH FN(wrapper CUDA Tensor rshift ));
m.impl("__irshift__.Tensor",
TORCH FN(wrapper CUDA Tensor irshift ));
m.impl("bitwise right shift.Tensor", TORCH FN(wrapper CUDA bitwise right shift Tensor))
m.impl("bitwise_right_shift.Tensor_out", TORCH_FN(wrapper_CUDA_bitwise_right_shift_out_
m.impl("bitwise right shift .Tensor", TORCH FN(wrapper CUDA bitwise right shift Tensor
m.impl("tril", TORCH FN(wrapper CUDA tril));
m.impl("tril.out", IORCH FN(wrapper CUDA tril out out));
m.impl("tril_", TORCH_FN(wrapper_CUDA_tril_));
m.impl("triu", TORCH_FN(wrapper_CUDA_triu));
m.impl("triu.out", TORCH FN(wrapper CUDA triu out out));
m.impl("triu ", TORCH FN(wrapper CUDA triu ));
m.impl("digamma", TORCH FN(wrapper CUDA digamma));
m.impl("digamma.out", TORCH FN(wrapper CUDA digamma out out));
m.impl("digamma ", TORCH FN(wrapper CUDA digamma ));
m.impl("lerp.Scalar", TORCH FN(wrapper CUDA lerp Scalar));
m.impl("lerp.Scalar out", TORCH FN(wrapper CUDA lerp out Scalar out));
m.impl("lerp .Scalar", TORCH FN(wrapper CUDA lerp Scalar));
m.impl("lerp.Tensor", TORCH FN(wrapper CUDA lerp Tensor));
m.impl("lerp.Tensor out", TORCH FN(wrapper CUDA lerp out Tensor out));
m.impl("lerp .Tensor", TORCH FN(wrapper CUDA lerp Tensor));
m.impl("addbmm",
TORCH FN(wrapper CUDA addbmm));
m.impl("addbmm.out",
TORCH FN(wrapper CUDA out addbmm out));
m.impl("addbmm",
TORCH FN(wrapper CUDA addbmm));
m.impl("random .from",
TORCH FN(wrapper CUDA from random ));
m.impl("random .to",
TORCH FN(wrapper CUDA to random ));
m.impl("random "
"pytorch/build/aten/src/ATen/RegisterCUDA.cpp" 50827L, 2715252B
```

同理,我们也需要给"tril"算子为 MUSA 后端实现注册。部分代码如下所示:

```
#include <torch/library.h>

namespace at {
namespace musa {

TORCH_LIBRARY_IMPL(aten, PrivateUse1, m) {
    m.impl("tril", Tril); // 'Tril' is a function implemented somewhere
}

} // namespace musa
} // namespace at
```

PyTorch 社区推荐使用 PrivateUse1 作为第三方扩展后端的 key,所以我们这里复用了 PrivateUse1。

6.2.2 利用 MUDNN 实现算子

如果 MUDNN 算子库支持了该算子,那么需要以 MUDNN 算子库作为后端来适配该新算子。使用 MUDNN 适配新算子的主要步骤如下:

- 1. tensor 的数据类型和 device 类型检查;
- 2. 添加 DeviceGuard;
- 3. 目前大部分 MUDNN 算子只支持连续的 tensor,因此在 createMUTensor 前需要将其转换为连续 tensor (如果该 tensor 不连续,此操作将会产生 copy 耗时);
- 4. 创建 muTensor;
- 5. 调用 MUDNN 的 op 实现接口;

以 addcdiv.out 算子为例, 部分代码如下:

```
#include <mudnn.h>
Tensor& AddcDivOut(const Tensor& base, const Tensor& tensor1,
                   const Tensor& tensor2, const Scalar& value, Tensor& out) {
 //1). check Dtype & device
 TORCH_CHECK(self.device().type() == kMUSA,
              "Device of input tensor of addcdiv must be MUSA, but now it is ",
              self.device());
 TORCH_CHECK(
     self.scalar_type() == at::ScalarType::Float,
     "Dtype of input tensor of addcdiv only support Float32, but now it is ",
     self.scalar_type());
  // 2).convert it to contiguous tensor
 Tensor tensor_cong = tensor1.contiguous();
  // 3). create muTensor, which binds the two variables by address.
 muTensor musa_tensor1 = CreateMUTensor(tensor_cong);
 muTensor mu_out = CreateMUTensor(tensor_cong);
  // 4). call musa op to implement the calculation.
  ::musa::dnn::Handle h;
  ::musa::dnn::Ternary mop;
 if (!alpha_scalar.equal(1)) {
   if (self.is_floating_point()) {
      CHECK_MUDNN_STATUS(mop.SetAlpha(alpha_scalar.toDouble()), "SetAlpha");
    } else {
```

```
CHECK_MUDNN_STATUS(mop.SetAlpha(alpha_scalar.toLong()), "SetAlpha");
}
CHECK_MUDNN_STATUS(mop.SetMode(TERNARY_MODE::ADDCDIV_ALPHA), "SetMode");
CHECK_MUDNN_STATUS(mop.Run(h, om_mt, musa_base, musa_tensor1, musa_tensor2), "Run");
}
TORCH_LIBRARY_IMPL(aten, PrivateUse1, m){
...
m.impl("addcdiv.out", &AddcDivOut);
}
```

通过 mudnn*.h 头文件可以查看到 MUDNN 算子库函数接口。默认 MUDNN 算子库的头文件会在/usr/local/musa/include 目录下。

6.2.3 利用 CUDA-Porting 实现算子

如果该算子 MUDNN 算子库不支持,那么我们需要通过 CUDA-Porting kernels 作为后端来适配新算子。 首先介绍一下 CUDA-Porting 的流程:

- 1. 在 torch_musa/build 下新建目录 (默认目录名是 torch_musa/build/generated_cuda_compatible) 用来保存 CUDA-Porting 过程需要用到的文件。
- 2. 从 PyTorch 仓 库 中 将 kernels 相 关 的 cu/cuh 文 件 以及 include 头文件复制到上一步新建目录中去。这些文件需要经过 CUDA-Porting 脚本的处理 (torch_musa/torch_musa/tools/cuda_porting/cuda_porting.py)。
- 3. 运行 porting 工具。主要是一些字符串替换处理,如将 cudaMalloc 替换成 musaMalloc, cuda_fp16.h 替换成 musa_fp16.h 等。
- 4. 经 过 上 述 操 作 后,build/generated_cuda_compatible/aten/src/ATen/native/musa/会 有 很 多 *****.mu 文件,这些 mu 文件就是我们适配时会用到的 kernels 文件。
- 5. 适配 CUDA-Porting 工具处理过的 kernels。

上述步骤 1, 2, 3, 4 会在编译过程中自动完成,适配新算子关心的步骤 5 即可。有一点需要注意的是,在 开发过程中引用的 PyTorch 头文件来自于 torch_musa/build/generated_cuda_compatible/include 目录,而不是系统下 PyTorch 安装目录下的头文件。

下面以两种典型算子为例,介绍如何利用 CUDA-Porting kernels 适配新算子。在开始适配之前,可以在pytorch/build/aten/src/ATen/RegisterCUDA.cpp 文件中查看该算子在 CUDA 中的实现方式。

6.2.3.1 以 abs 算子为例

CUDA 中 abs 算子的部分适配代码如下:

```
at::Tensor & wrapper_CUDA_out_abs_out(const at::Tensor & self, at::Tensor & out) {
    // No device check
const OptionalDeviceGuard device_guard(device_of(self));
return at::native::abs_out(self, out);
}

******
m.impl("abs.out", TORCH_FN(wrapper_CUDA_out_abs_out));
```

如果该算子直接调用了 at::native 下面的函数接口,那么我们也这么做就可以了:

```
#include "torch_musa/csrc/core/MUSAGuard.h"
at::Tensor& MusaAbsout(const at::Tensor& self, at::Tensor& out) {
c10::musa::MUSAGuard device_gaurd(self.device());
return at::native::abs_out(self, out);
}

TORCH_LIBRARY_IMPL(aten, PrivateUse1, m) {
   m.impl("abs.out", &MusaAbsout);
}
```

这里的关键是 PyTorch 仓库提供了 DispatchStub 机制。我们在 CUDA-Porting 时,将 REGISTER_CUDA_DISPATCH 替换成 REGISTER_MUSA_DISPATCH,从而能实现根据 device 类型调用到 porting 后的 kernels。对这背后机制感兴趣的话,可以查看一下如下几个文件:

- abs_out 函数实现: https://github.com/pytorch/pytorch/blob/v2.0.0/aten/src/ATen/native/ UnaryOps.cpp#L546
- abs_stub 注 册: https://github.com/pytorch/pytorch/blob/v2.0.0/aten/src/ATen/native/cuda/ AbsKernel.cu#L49
- DispatchStub 定 义: https://github.com/pytorch/pytorch/blob/v2.0.0/aten/src/ATen/native/DispatchStub.h

6.2.3.2 以 tril 算子为例

CUDA中 tril 算子的部分适配代码如下:

```
struct structured_tril_cuda_functional final : public at::native::structured_tril_cuda {
    void set_output_strided(
        int64_t output_idx, IntArrayRef sizes, IntArrayRef strides,
        TensorOptions options, DimnameList names
    ) override {
        auto current_device = guard_.current_device();
        if (C10_UNLIKELY(current_device.has_value())) {
         TORCH_INTERNAL_ASSERT(*current_device == options.device(),
            "structured kernels don't support multi-device outputs");
        } else {
          guard_.reset_device(options.device());
        outputs_[output_idx] = create_out(sizes, strides, options);
       if (!names.empty()) {
         namedinference::propagate_names(*outputs_[output_idx], names);
        // super must happen after, so that downstream can use maybe_get_output
        // to retrieve the output
   }
   void set_output_raw_strided(
        int64_t output_idx, IntArrayRef sizes, IntArrayRef strides,
        TensorOptions options, DimnameList names
    ) override {
        auto current_device = guard_.current_device();
        if (C10_UNLIKELY(current_device.has_value())) {
         TORCH_INTERNAL_ASSERT(*current_device == options.device(),
            "structured kernels don't support multi-device outputs");
        } else {
         guard_.reset_device(options.device());
        outputs_[output_idx] = create_out(sizes, strides, options);
        if (!names.empty()) {
         namedinference::propagate_names(*outputs_[output_idx], names);
        // super must happen after, so that downstream can use maybe_get_output
        // to retrieve the output
    const Tensor& maybe_get_output(int64_t output_idx) override {
```

```
return *outputs_[output_idx];
}
std::array<c10::ExclusivelyOwned<Tensor>, 1> outputs_;
c10::cuda::OptionalCUDAGuard guard_;
};
at::Tensor wrapper_CUDA_tril(const at::Tensor & self, int64_t diagonal) {
c10::optional<Device> common_device = nullopt;
(void)common_device; // Suppress unused variable warning
c10::impl::check_and_update_common_device(common_device, self, "wrapper_CUDA_tril", "self");
structured_tril_cuda_functional op;
op.meta(self, diagonal);
op.impl(self, diagonal, *op.outputs_[0]);
return std::move(op.outputs_[0]).take();
}
******
m.impl("tril", TORCH_FN(wrapper_CUDA_tril));
```

该算子在实现时继承了基类 at::native::structured_tril_cuda,那么我们也需要这么实现:

```
#include <ATen/ops/tril_native.h>
#include "torch musa/csrc/aten/utils/Utils.h"
#include "torch_musa/csrc/core/MUSAGuard.h"
namespace at {
namespace musa {
namespace {
struct structured_tril_musa_functional final
    : public at::native::structured_tril_cuda {
  void set_output_strided(
     int64_t output_idx,
     IntArrayRef sizes,
     IntArrayRef strides,
     TensorOptions options,
     DimnameList names) override {
    auto current_device = guard_.current_device();
    if (C10_UNLIKELY(current_device.has_value())) {
     TORCH_INTERNAL_ASSERT(
          *current_device == options.device(),
          "structured kernels don't support multi-device outputs");
```

```
} else {
      guard_.reset_device(options.device());
   }
    outputs_[output_idx] = create_out(sizes, strides, options);
 }
  void set_output_raw_strided(
     int64_t output_idx,
      IntArrayRef sizes,
      IntArrayRef strides,
      TensorOptions options,
      DimnameList names) override {
    auto current_device = guard_.current_device();
    if (C10_UNLIKELY(current_device.has_value())) {
      TORCH_INTERNAL_ASSERT(
          *current_device == options.device(),
          "structured kernels don't support multi-device outputs");
    } else {
      guard_.reset_device(options.device());
   }
    outputs_[output_idx] = create_out(sizes, strides, options);
 const Tensor& maybe_get_output(int64_t output_idx) override {
   return *outputs_[output_idx];
 }
  std::array<c10::ExclusivelyOwned<Tensor>, 1> outputs_;
  c10::musa::OptionalMUSAGuard guard_;
};
} // namespace
Tensor Tril(const Tensor& self, int64_t diagonal) {
  structured_tril_musa_functional op;
 op.meta(self, diagonal);
 op.impl(self, diagonal, *op.outputs_[0]);
 return std::move(op.outputs_[0]).take();
} // namespace musa
} // namespace at
```

至此,我们已经完成了通过 CUDA-Porting kernels 来适配新算子。

6.2.4 利用 CPU 实现算子

对于部分算子,如果 MUDNN 不支持,CUDA-Porting 也无法支持,可以临时中利用 CPU 后端实现该算子。主要逻辑是,先把 tensor 拷贝到 CPU 侧,在 CPU 完成计算,再将结果拷贝到 GPU 侧。可以参考下述代码:

```
Tensor& AddcDivOut(const Tensor& base, const Tensor& tensor1,
                     const Tensor& tensor2, const Scalar& value, Tensor& out) {
  auto cpu_base =
     at::empty(base.sizes(), base.options().device(DeviceType::CPU));
  auto cpu_factor1 =
     at::empty(tensor1.sizes(), tensor1.options().device(DeviceType::CPU));
  auto cpu_factor2 =
     at::empty(tensor2.sizes(), tensor2.options().device(DeviceType::CPU));
  auto cpu_out =
     at::empty(out.sizes(), out.options().device(DeviceType::CPU));
  cpu_base.copy_(base);
 cpu_factor1.copy_(tensor1);
  cpu_factor2.copy_(tensor2);
  auto result = addcdiv_out(cpu_out, cpu_base, cpu_factor1, cpu_factor2);
  out.copy_(cpu_out);
  return out;
```

6.2.5 添加算子单元测试

如果已经完成了新算子的适配,那么还需要添加算子单元测试,保证算子适配结果的正确性。算子测试 文件在 torch_musa/tests/unittest/operator 目录下,参考已有算子测试添加即可,在此不展开描述。 算子测试命令如下:

```
pytest -s torch_musa/tree/main/tests/unittest/operator/xxxx.py
```

6.2.6 即将支持的特性

引入 codegen 模块,实现算子的注册代码和实现代码的生成,能进一步简化算子适配的工作量。请关注 这部分工作。



7自定义算子支持

7.1 支持自定义算子

待完善。



8第三方库 MUSA 扩展支持

本节主要介绍如何对 PyTorch 生态的第三方库进行 MUSA 扩展的构建 (MUSAExtension),对应于 CUDAExtension。

8.1 为什么要对第三方库进行 MUSA 扩展的构建?

以 mmcv 库 (commit id 为 0a2f60ba0198f8d567b536313bfba329588f9c3f) 为例,当我们的测试代码有如下报错 log,则说明 mmcv 中没有构建 MUSA 扩展。此时,我们需要对 mmcv 库进行 MUSA 扩展,从而使得 mmcv 库运行在摩尔线程显卡上。

```
import numpy as np
import torch
import torch_musa
from mmcv.ops import nms
np_boxes = np.array([[6.0, 3.0, 8.0, 7.0], [3.0, 6.0, 9.0, 11.0],
                      [3.0, 7.0, 10.0, 12.0], [1.0, 4.0, 13.0, 7.0]],
                      dtype=np.float32)
np_scores = np.array([0.6, 0.9, 0.7, 0.2], dtype=np.float32)
np_inds = np_array([1, 0, 3])
np_dets = np.array([[3.0, 6.0, 9.0, 11.0, 0.9],
                    [6.0, 3.0, 8.0, 7.0, 0.6],
                    [1.0, 4.0, 13.0, 7.0, 0.2]])
boxes = torch.from_numpy(np_boxes)
scores = torch.from_numpy(np_scores)
# check if cpu can work
dets, inds = nms(boxes, scores, iou_threshold=0.3, offset=0)
# check if musa can work
dets, inds = nms(boxes.musa(), scores.musa(), iou_threshold=0.3, offset=0)
```

注意以上测试不要在 mmcv 根目录下进行,以免将当前目录下的 mmcv 包导入。

8.2 如何对第三方库进行 MUSA 扩展?

8.2.1 了解 MUSAExtension 这个 API

阅读 torch_musa/utils/README.md 中关于 MUSAExtension 的介绍。

8.2.2 CUDA-Porting

我们需要先找到与 CUDA 相关文件所在的位置,在 mmcv 中,有如下几处:

- mmcv/mmcv/ops/csrc/common/cuda/
- mmcv/mmcv/ops/csrc/pytorch/cuda/

为了方便我们将对 mmcv/mmcv/ops/csrc 这个目录进行 CUDA-Porting, 将会生成mmcv/mmcv/ops/csrc_musa 目录。

同时也为了减少不必要的 Porting, 我们将如下几个目录进行忽略:

- mmcv/ops/csrc/common/mlu
- mmcv/ops/csrc/common/mps
- mmcv/mmcv/ops/csrc/parrots
- mmcv/mmcv/ops/csrc/pytorch/mlu
- mmcv/mmcv/ops/csrc/pytorch/mps
- mmcv/mmcv/ops/csrc/pytorch/npu

之后从 mmcv 根目录全局搜索 cu、nv、cuda 和对应的大写关键词。搜索关键词的目的在于梳理自定义的映射规则,本次对搜索结果的映射规则提取如下:

- CU H -> MU H
- _CUH -> _MUH

- __NVCC__ -> __MUSACC__
- MMCV WITH CUDA -> MMCV WITH MUSA
- AT_DISPATCH_FLOATING_TYPES_AND_HALF -> AT_DISPATCH_FLOATING_TYPES
- #include <c10/cuda/CUDAGuard.h> -> #include "torch_musa/csrc/core/MUSAGuard.h"
- ::cuda:: -> ::musa:
- /cuda/ -> /musa/
- , CUDA, -> , PrivateUse1,
- .cuh -> .muh
- .is_cuda() -> .is_privateuseone()

大多数情况下,有一些基本的映射规则即 cu->mu、nv->mt、cuda->musa、cuh->muh 及对应的大写映射。如果在编译过程中遇到 HALF 相关的编译报错,可以如上所示将 HALF 相关的宏取消掉。然后我们将搜索出来的关键词拓展,形成单词边界然后进行 映射,如果直接 cu->mu 那么就会产生 Accumulate->Acmumulate 这样的不期望的结果。第 3、6、7、10、12 个规则是一些固定的转换,其中 PrivateUse1 是 PyTorch 中对于扩展的自定义 backend 默认名字,is_privateuseone 也是属于自定义 backend 相关的 API。

因此由上述分析我们得到如下 CUDA-porting 脚本:

```
SimplePorting(cuda_dir_path="./mmcv/ops/csrc", ignore_dir_paths=[
              "./mmcv/ops/csrc/common/mlu",
              "./mmcv/ops/csrc/common/mps",
              "./mmcv/ops/csrc/parrots",
              "./mmcv/ops/csrc/pytorch/mlu",
              "./mmcv/ops/csrc/pytorch/mps",
              "./mmcv/ops/csrc/pytorch/npu"
              ],
              mapping_rule={
                  "_CU_H_": "_MU_H_",
                  "_CUH": "_MUH",
                  "__NVCC__": "__MUSACC__",
                  "MMCV_WITH_CUDA": "MMCV_WITH_MUSA",
                  "AT_DISPATCH_FLOATING_TYPES_AND_HALF": "AT_DISPATCH_FLOATING_TYPES",
                  "#include <ATen/cuda/CUDAContext.h>": "#include \"torch_musa/csrc/aten/musa/

→MUSAContext.h\"",
                  "#include <c10/cuda/CUDAGuard.h>": "#include \"torch_musa/csrc/core/
→MUSAGuard.h\"",
                  "::cuda::": "::musa::",
                  "/cuda/": "/musa/",
                  ", CUDA,": ", PrivateUse1,",
```

```
".cuh": ".muh",

".is_cuda()": ".is_privateuseone()",
}
).run()
```

需要注意的是尽管我们自定义了映射规则,但是我们没有传入 drop_default_mapping 参数,因此在 CUDA-porting 时还会使用默认的映射规则,见 torch_musa/utils/mapping 文件夹。由于文件夹下的 general.json 条目过多,并且基本上不会被用到,所以默认的映射规则里只包含除了 它之外的其他映射规则(mapping 文件夹中除了 general.json 之外的其他 json 文件),general.json 可作为自定义映射规则的参考。如果不 想在代码里添加映射规则,也可以在 extra.json 文件中添加条目或者自行添加新的 json 文件。

8.2.3 分析 mmcv 的构建脚本 setup.py

```
elif is_rocm_pytorch or torch.cuda.is_available() or os.getenv(
    'FORCE_CUDA', '0') == '1':
if is_rocm_pytorch:
    define_macros += [('MMCV_WITH_HIP', None)]
define_macros += [('MMCV_WITH_CUDA', None)]
cuda_args = os.getenv('MMCV_CUDA_ARGS')
extra_compile_args['nvcc'] = [cuda_args] if cuda_args else []
op_files = glob.glob('./mmcv/ops/csrc/pytorch/*.cpp') + \
    glob.glob('./mmcv/ops/csrc/pytorch/cpu/*.cpp') + \
   glob.glob('./mmcv/ops/csrc/pytorch/cuda/*.cu') + \
    glob.glob('./mmcv/ops/csrc/pytorch/cuda/*.cpp')
extension = CUDAExtension
include_dirs.append(os.path.abspath('./mmcv/ops/csrc/pytorch'))
include_dirs.append(os.path.abspath('./mmcv/ops/csrc/common'))
include_dirs.append(os.path.abspath('./mmcv/ops/csrc/common/cuda'))
elif (hasattr(torch, 'is_mlu_available') and
```

在 CUDA 扩展的构建逻辑中,我们可以看到有环境变量'FORCE_CUDA' 来控制是否构建,也可以看到有 CUDA 相关的宏定义'MMCV_WITH_CUDA',赋值 extension 为 CUDAExtension,然后就是源文件以及头文件的设置。因此我们也可以加一个 elif 分支并利用环境变量'FORCE_MUSA' 来控制是否构建,然后添加宏定义'MMCV_WITH_MUSA'。为了方便,我们直接对 mmcv/mmcv/ops/csrc 这个目录进行CUDA-porting,会生成 mmcv/mmcv/ops/csrc_musa。所以我们在设置源 文件以及头文件的路径时只需将 csrc 改为 csrc_musa,最后将 extension 赋值为 MUSAExtension 就可以了。增加的分支如下所示:

```
elif os.getenv('FORCE_MUSA', '0') == '1':
  from torch_musa.utils.simple_porting import SimplePorting
 from torch_musa.utils.musa_extension import MUSAExtension
 SimplePorting(cuda_dir_path="./mmcv/ops/csrc", ignore_dir_paths=[
  "./mmcv/ops/csrc/common/mlu",
  "./mmcv/ops/csrc/common/mps",
  "./mmcv/ops/csrc/parrots",
  "./mmcv/ops/csrc/pytorch/mlu",
  "./mmcv/ops/csrc/pytorch/mps",
  "./mmcv/ops/csrc/pytorch/npu"
 ],
 mapping_rule={
      "_CU_H_": "_MU_H_",
     "_CUH": "_MUH",
     "__NVCC__": "__MUSACC__",
     "MMCV_WITH_CUDA": "MMCV_WITH_MUSA",
     "AT_DISPATCH_FLOATING_TYPES_AND_HALF": "AT_DISPATCH_FLOATING_TYPES",
     "#include <ATen/cuda/CUDAContext.h>": "#include \"torch_musa/csrc/aten/musa/MUSAContext.
⇔h\"".
     "#include <c10/cuda/CUDAGuard.h>": "#include \"torch musa/csrc/core/MUSAGuard.h\"",
     "::cuda::": "::musa::",
     "/cuda/": "/musa/",
     ", CUDA,": ", PrivateUse1,",
      ".cuh": ".muh",
     ".is_cuda()": ".is_privateuseone()",
     ).run()
  op_files = glob.glob('./mmcv/ops/csrc_musa/pytorch/*.cpp') + \
     glob.glob('./mmcv/ops/csrc_musa/pytorch/cpu/*.cpp') + \
     glob.glob('./mmcv/ops/csrc_musa/pytorch/cuda/*.mu') + \
     glob.glob('./mmcv/ops/csrc_musa/pytorch/cuda/*.cpp')
  define_macros += [
      ('MMCV_WITH_MUSA', None)
     1
  extension = MUSAExtension
  include_dirs.append(os.path.abspath('./mmcv/ops/csrc_musa/pytorch'))
  include_dirs.append(os.path.abspath('./mmcv/ops/csrc_musa/common'))
 include_dirs.append(os.path.abspath('./mmcv/ops/csrc_musa/common/cuda'))
elif (hasattr(torch, 'is_mlu_available') and
```

由于构建 MUSA 扩展时生成了额外的共享库,然后它会被链接到最终的目标库,因此在安装包时它需要被一起打包,具体示例见 torch_musa/utils/README.md。mmcv 中是以设置'include_package_data=True' 和配置 MANIFEST.in 文件来控制需要打包的数据的,原始 MANIFEST.in 文件如下所示:

修改之后如下所示:

仅仅将 csrc 批量替换成 csrc_musa 并加入生成的额外的共享库的路径即可。

8.2.4 尝试构建并测试

由于本次实验是在 MTT S3000 上进行,对应的 MUSA 架构版本为 21,而 mmcv 中涉及到 fp64 的使用,所以我们也要打开这个选项。对于这些额外的环境变量,可以参 考 torch_musa 根目录下的 CMakeLists.txt 和 build.sh。

接下来,我们尝试执行'MUSA_ARCH=21 ENABLE_COMPILE_FP64=1 FORCE_MUSA=1 python setup.py install > build.log' 构建 mmcv 并记录构建日志。很不幸,在第一次构建时遇到了一些编译错误,其中一个如下图所示:

```
/usr/local/musa/bin/mcc <mark>/home/mmcv/mmcv/ops/csrc_musa/pytorch/cuda/upfirdn2d_kernel.mu</mark> -c -o /home/mmcv/build/MMCV/CMakeFiles/mmcv_
t.dir/mmcv/ops/csrc_musa/pytorch/cuda/./mmcv_ext_generated_upfirdn2d_kernel.mu.o -fPIC -m64 -Dmmcv_ext_EXPORTS -DMMCV_WITH_MUSA -02 -fPIC -Wall -Wextra -Wno-unused-parameter -Wno-unused-variable -Wno-unused-function -Wno-sign-compare -Wno-missing-field-initializers
-fno-math-errno -fno-trapping-math -Werror=format -Werror=cast-function-type -Wno-unused-parameter -Wno-unused-variable -Wno-sign-comp
uda_compatible/include -I/opt/conda/envs/py38/lib/python3.8/site-packages/torch_musa/share/generated_cuda_compatible/include/torch/csr
c/api/include -I/opt/conda/envs/py38/lib/python3.8/site-packages -I/home/mmcv/mmcv/ops/csrc_musa/pytorch -I/home/mmcv/oms/csrc_musa/common -I/home/mmcv/ops/csrc musa/common -I/home/mmcv/ops/csrc musa/common/cuda -I/usr/local/musa/include -I/opt/conda/envs/py38/include/python3.8
 error: shared memory (42904) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi1ELi24ELi24ELi64ELi32ELi1EE
v23upfirdn2d kernel params
     or: shared memory (31768) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi1ELi16ELi16ELi64ELi32ELi1EE
v23upfirdn2d_kernel_params
error: shared memory (28824) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi1ELi1ELi24ELi24ELi32ELi32ELi31ELi1EE
v23upfirdn2d_kernel_params
3upfirdn2d kernel params
error: shared memory (41776) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi1ELi2ELi24ELi24ELi34ELi34ELi16ELi1EE
v23upfirdn2d kernel params
error: shared memory (30768) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi1ELi16ELi16ELi16ELi3ELi16ELi1EL
v23upfirdn2d kernel params
error: shared memory (31504) exceeds limit (28672) in function '_ZL22upfirdn2d_kernel_smallIdLi1ELi1ELi1ELi2ELi2ELi8ELi8ELi8ELi8EELi8EEv23u
pfirdn2d_kernel_params'
7 errors generated when compiling for mp 10.
 -- Removing /home/mmcv/build/MMCV/CMakeFiles/mmcv_ext.dir/mmcv/ops/csrc_musa/pytorch/cuda/./mmcv_ext_generated_upfirdn2d_kernel.mu.o
/opt/conda/envs/py38/lib/python3.8/site-packages/cmake/data/bin/cmake - E remove /home/mmcv/build/MMCV/CMakeFiles/mmcv\_ext.dir/mmcv/opt/conda/envs/py38/lib/python3.8/site-packages/cmake/data/bin/cmake - E remove /home/mmcv/build/MMCV/CMakeFiles/mmcv\_ext.dir/mmcv/opt/conda/envs/py38/lib/python3.8/site-packages/cmake/data/bin/cmake - E remove /home/mmcv/build/MMCV/CMakeFiles/mmcv\_ext.dir/mmcv/opt/conda/envs/py38/lib/python3.8/site-packages/cmake/data/bin/cmake - E remove /home/mmcv/build/MMCV/CMakeFiles/mmcv\_ext.dir/mmcv/opt/conda/envs/py38/lib/python3.8/site-packages/cmake/data/bin/cmake - E remove /home/mmcv/build/MMCV/CMakeFiles/mmcv_ext.dir/mmcv/opt/cmake - E remove /home/mmcv/build/mmcv/cmakeFiles/mmcv.ext.dir/mmcv/opt/cmake - E remove /home/mmcv/build/mmcv/cmakeFiles/mmcv.ext.dir/mmcv/opt/cmake - E remove /home/mmcv/build/mmcv/cmakeFiles/mmcv/cmake - E remove /home/mmcv/cmakeFiles/mmcv/cmake - E remove /home/mmcv/cmake - E remove /hom
s/csrc_musa/pytorch/cuda/./mmcv__ext_generated_upfirdn2d_kernel.mu.o
CMake Error at mmcv_ext_generated_upfirdn2d_kernel.mu.o.Release.cmake:283 (message):
   Error generating file
    /home/mmcv/build/MMCV/CMakeFiles/mmcv_ext.dir/mmcv/ops/csrc_musa/pytorch/cuda/./mmcv_ext_generated_upfirdn2d_kernel.mu.o
```

这是由于定义的结构体(upfirdn2d_kernel_params)要使用的 shared memory 过大,超过了硬件(此次编译是在 MTT S3000 上进行的)规格的限制,因此我们尝试避免构建该 kernel 的 musa 扩展(mmcv/mmcv/ops/csrc_musa/pytorch/cuda/upfirdn2d_kernel.mu)。如果您的模型中没有真实用到该 kernel,那么可以将其注释起来,临时绕过该算子,保证模型的正常运行。如果您的模型确认需要使用该 kernel,那么请联系摩尔线程 AI 研发中心,反馈该问题(在外网提 issue),我们及时修复。同理,对于其他的编译错误也是可以进行类似的修改。

汇总一下,我们对 mmcv 进行 MUSA 适配需要修改如下文件:

- MANIFEST.in
- mmcv/ops/csrc/common/cuda/carafe_cuda_kernel.cuh
- mmcv/ops/csrc/common/cuda/chamfer_distance_cuda_kernel.cuh
- mmcv/ops/csrc/common/cuda/scatter_points_cuda_kernel.cuh
- mmcv/ops/csrc/pytorch/cuda/upfirdn2d_kernel.cu
- setup.py

再次测试本节开头的例子, 我们得到结果如下:

```
>>> import torch_musa
>>> from mmcv.ops import nms
>>> np_boxes = np.array([[6.0, 3.0, 8.0, 7.0], [3.0, 6.0, 9.0, 11.0],
                          [3.0, 7.0, 10.0, 12.0], [1.0, 4.0, 13.0, 7.0]],
. . .
                          dtype=np.float32)
. . .
>>> np_scores = np.array([0.6, 0.9, 0.7, 0.2], dtype=np.float32)
>>> np_inds = np.array([1, 0, 3])
>>> np_dets = np.array([[3.0, 6.0, 9.0, 11.0, 0.9],
                        [6.0, 3.0, 8.0, 7.0, 0.6],
. . .
                        [1.0, 4.0, 13.0, 7.0, 0.2]])
. . .
>>> boxes = torch.from numpy(np boxes)
>>> scores = torch.from numpy(np scores)
>>> # check if cpu can work
>>> dets, inds = nms(boxes, scores, iou threshold=0.3, offset=0)
>>> # check if musa can work
>>> dets, inds = nms(boxes.musa(), scores.musa(), iou_threshold=0.3, offset=0)
>>> dets
tensor([[ 3.0000, 6.0000, 9.0000, 11.0000,
                                              0.9000],
        [ 6.0000, 3.0000, 8.0000, 7.0000, 0.6000],
        [ 1.0000, 4.0000, 13.0000, 7.0000, 0.2000]], device='musa:0')
>>>
```

当然这并不能证明适配的 mmcv 的功能完全,我们可以对 mmcv 自带的单元测试进行简单的改动就可以进行测试了。如 tests/test_ops/test_box_iou_quadri.py:

```
# Copyright (c) OpenMMLab. All rights reserved.
import numpy as np
import pytest
import torch
import torch_musa
# from mmcv.utils import IS_CUDA_AVAILABLE
class TestBoxIoUQuadri:
    @pytest.mark.parametrize('device', [
        'cpu',
        pytest.param(
            'musa',
            marks=pytest.mark.skipif(
                not True, reason='requires MUSA support')),
   def test_box_iou_quadri_musa(self, device):
        from mmcv.ops import box_iou_quadri
        np_boxes1 = np.asarray([[1.0, 1.0, 3.0, 4.0, 4.0, 4.0, 4.0, 1.0],
                                [2.0, 2.0, 3.0, 4.0, 4.0, 2.0, 3.0, 1.0],
```

```
[7.0, 7.0, 8.0, 8.0, 9.0, 7.0, 8.0, 6.0]],
                          dtype=np.float32)
    np_boxes2 = np.asarray([[0.0, 0.0, 0.0, 2.0, 2.0, 2.0, 2.0, 0.0],
                            [2.0, 1.0, 2.0, 4.0, 4.0, 4.0, 4.0, 1.0],
                            [7.0, 6.0, 7.0, 8.0, 9.0, 8.0, 9.0, 6.0]],
                          dtype=np.float32)
   np_expect_ious = np.asarray(
        [[0.0714, 1.0000, 0.0000], [0.0000, 0.5000, 0.0000],
        [0.0000, 0.0000, 0.5000]],
        dtype=np.float32)
    np_expect_ious_aligned = np.asarray([0.0714, 0.5000, 0.5000],
                                        dtype=np.float32)
    boxes1 = torch.from_numpy(np_boxes1).to(device)
    boxes2 = torch.from_numpy(np_boxes2).to(device)
    ious = box_iou_quadri(boxes1, boxes2)
    assert np.allclose(ious.cpu().numpy(), np_expect_ious, atol=1e-4)
    ious = box_iou_quadri(boxes1, boxes2, aligned=True)
    assert np.allclose(
        ious.cpu().numpy(), np_expect_ious_aligned, atol=1e-4)
@pytest.mark.parametrize('device', [
    'cpu',
    pytest.param(
        'musa',
        marks=pytest.mark.skipif(
            not True, reason='requires MUSA support')),
1)
def test_box_iou_quadri_iof_musa(self, device):
    from mmcv.ops import box_iou_quadri
    np_boxes1 = np.asarray([[1.0, 1.0, 3.0, 4.0, 4.0, 4.0, 4.0, 1.0],
                            [2.0, 2.0, 3.0, 4.0, 4.0, 2.0, 3.0, 1.0],
                             [7.0, 7.0, 8.0, 8.0, 9.0, 7.0, 8.0, 6.0]],
                          dtype=np.float32)
    np_boxes2 = np.asarray([[0.0, 0.0, 0.0, 2.0, 2.0, 2.0, 2.0, 0.0],
                            [2.0, 1.0, 2.0, 4.0, 4.0, 4.0, 4.0, 1.0],
                            [7.0, 6.0, 7.0, 8.0, 9.0, 8.0, 9.0, 6.0]],
                          dtype=np.float32)
    np_expect_ious = np.asarray(
        [[0.1111, 1.0000, 0.0000], [0.0000, 1.0000, 0.0000],
```

我们进入到 mmcv/tests/test_ops 目录下,然后执行'pytest -s test_box_iou_quadri.py' 就可以测试该单元测试用例了,测试结果如下所示:



9调试工具

9.1 CompareTool 使用指南

如果发现模型准确率不对,可以通过算子精度对比工具来快速找出异常算子并进行修复。对比工具基于 PyTorch 的 Dispatcher² 和 DispatchMode³ 实现。在算子被 dispatch 到 MUSA device 之前捕获到调用 函数,然后分别调用 CPU 算子函数和 MUSA 算子函数进行计算,得出结果进行对比。所有算子(包括前向算子和反向算子)都会被依次 dispatch 并输出对比结果到日志,通过查询日志可以快速定位出第一个出现计算异常的算子。该工具在训练和推理中都能被使用。

9.1.1 基本用法

```
from torch_musa.utils.compare_tool import CompareWithCPU

with CompareWithCPU(atol=0.001, rtol=0.001, verbose=True):
    ...original code...
```

在这段代码中,CompareWithCPU 工具被用来比较在 MUSA 设备上执行算子作和在 CPU 上执行的相同算子的结果。这里,atol 和 rtol 分别代表绝对公差和相对公差,用于在比较时确定允许的误差范围。当 verbose 设置为 True 时,它会输出更详细的信息,包括输入输出 tensor 的 shape、dtype、stride、nan_num 等信息。

9.1.2 输出示例

输出内容大致如下:

² http://blog.ezyang.com/2020/09/lets-talk-about-the-pytorch-dispatcher/

³ https://dev-discuss.pytorch.org/t/torchdispatchmode-for-debugging-testing-and-more/717

```
..... compare with cpu ......
{\tt torch.\_ops.aten...div.Tensor}\ {\tt succeeds}\ {\tt to}\ {\tt pass}\ {\tt CompareWithCPU}\ {\tt test}
_____
torch._ops.aten..._to_copy.default
..... input ......
0: Tensor <shape=torch.Size([48, 3, 6, 6]), stride=(108, 1, 18, 3), dtype=torch.float32,__

device=musa:0, size=5184,>,

device=musa:0, size=5184,>,
..... output .....
Tensor <shape=torch.Size([48, 3, 6, 6]), stride=(108, 1, 18, 3), dtype=torch.float16,__

device=musa:0, size=5184,>
..... compare with cpu ......
torch._ops.aten..._to_copy.default succeeds to pass CompareWithCPU test
______
torch._ops.aten..._to_copy.default
..... input .....
0: Tensor <shape=torch.Size([16, 3, 640, 640]), stride=(1228800, 409600, 640, 1), dtype=torch.
→float32, device=musa:0, size=19660800,>,
..... output .....
Tensor <shape=torch.Size([16, 3, 640, 640]), stride=(1228800, 409600, 640, 1), dtype=torch.
→float16, device=musa:0, size=19660800,>
..... compare with cpu ......
torch._ops.aten..._to_copy.default succeeds to pass CompareWithCPU test
_____
torch._ops.aten...convolution.default
..... input .....
0: Tensor <shape=torch.Size([16, 3, 640, 640]), stride=(1228800, 409600, 640, 1), dtype=torch.
→float16, device=musa:0, size=19660800,>,
1: Tensor <shape=torch.Size([48, 3, 6, 6]), stride=(108, 1, 18, 3), dtype=torch.float16, u
\rightarrowdevice=musa:0, size=5184,>,
2: None,
3: [2, 2, ],
4: [2, 2, ],
```

```
5: [1, 1, ],
6: False,
7: [0, 0, ],
8: 1,
..... output .....
Tensor <shape=torch.Size([16, 48, 320, 320]), stride=(4915200, 1, 15360, 48), dtype=torch.
→float16, device=musa:0, size=78643200,>
..... compare with cpu ......
"slow_conv2d_cpu" not implemented for 'Half'
Convert to float32 ...
..... output 0 is not close ......
Too many indices (total 2388336) to print
Element at index (0, 3, 1, 75) is not close: 0.5458984375 vs 0.5460812449455261
Element at index (0, 3, 1, 78) is not close: 0.5498046875 vs 0.5499854683876038
Element at index (0, 3, 1, 86) is not close: 0.55029296875 vs 0.5501253008842468
Element at index (0, 3, 1, 88) is not close: 0.55126953125 vs 0.5510903000831604
Element at index (0, 3, 1, 91) is not close: 0.55029296875 vs 0.5504764914512634
Element at index (0, 3, 1, 94) is not close: 0.54296875 vs 0.5427778959274292
Element at index (0, 3, 1, 101) is not close: 0.5361328125 vs 0.5359049439430237
Element at index (0, 3, 1, 103) is not close: 0.54638671875 vs 0.5466215014457703
Element at index (0, 3, 1, 104) is not close: 0.54296875 vs 0.5431610941886902
Element at index (0, 3, 1, 108) is not close: 0.54296875 vs 0.5427677631378174
Element at index (0, 3, 1, 110) is not close: 0.5390625 vs 0.5392988920211792
Element at index (0, 3, 1, 112) is not close: 0.5009765625 vs 0.5012078881263733
Element at index (0, 3, 1, 114) is not close: 0.54052734375 vs 0.5403239130973816
Element at index (0, 3, 1, 115) is not close: 0.5361328125 vs 0.5363231897354126
Element at index (0, 3, 1, 117) is not close: 0.5234375 vs 0.5236586332321167
Element at index (0, 3, 1, 118) is not close: 0.5029296875 vs 0.5027626156806946
Element at index (0, 3, 1, 133) is not close: 0.537109375 vs 0.5373141765594482
Element at index (0, 3, 1, 136) is not close: 0.513671875 vs 0.5134815573692322
Element at index (0, 3, 1, 143) is not close: 0.5029296875 vs 0.5031570196151733
Element at index (0, 3, 1, 144) is not close: 0.51953125 vs 0.519349217414856
tensor 1: shape=torch.Size([16, 48, 320, 320]), numbers of nan = 0 of 78643200, numbers of \inf_{\square}
\rightarrow= 0 of 78643200
tensor([[[[-1.47583e-01, -1.81030e-01, -1.80420e-01, ..., -1.57349e-01, -1.55396e-01, -1.
\rightarrow71204e-02],
```

```
[-1.83838e-01, -1.55762e-01, -1.54785e-01, ..., -1.35498e-01, -1.33667e-01, 3.33252e-
 →02],
                      [-1.81885e-01, -1.56128e-01, -1.56738e-01, ..., -1.50024e-01, -1.37939e-01, 3.04413e-
 →02],
                      ..., ], device='musa:0', dtype=torch.float16)
tensor 2 (golden): shape=torch.Size([16, 48, 320, 320]), numbers of nan = 0 of 78643200, __
 \rightarrownumbers of inf = 0 of 78643200
\texttt{tensor}(\texttt{[[[[-1.47546e-01, -1.81061e-01, -1.80469e-01, \dots, -1.57394e-01, -1.55356e-01, -1.80469e-01, \dots, -1.57394e-01, -1.55356e-01, -1.80469e-01, \dots, -1.57394e-01, -1.55356e-01, -1.80469e-01, \dots, -1.57394e-01, 
 \hookrightarrow 71164e-021.
                      [-1.83810e-01, -1.55728e-01, -1.54838e-01, \dots, -1.35546e-01, -1.33724e-01, 3.33278e-01]
 →02],
                       [-1.81920e-01, -1.56185e-01, -1.56751e-01, ..., -1.49999e-01, -1.37939e-01, 3.04426e-01]
 ⇔02],
                      [-1.57577e-01, -1.27439e-01, -1.29771e-01, ..., -1.27387e-01, -1.08608e-01, 1.68391e-
 →021.
                      [-1.57745 e-01, -1.29170 e-01, -1.31028 e-01, \dots, -1.31670 e-01, -1.23129 e-01, 1.17836 e-01]
 ⇔02],
                      →02]],
                      ])
all_resuls=[False]
[ERROR] torch._ops.aten...convolution.default fails to pass CompareWithCPU test
```

这 段 输 出 显 示 了 在 MUSA 设 备 上 执 行 的 torch._ops.aten.div.Tensor, torch._ops.aten._to_copy.default, torch._ops.aten.convolution.default 算子和在 CPU 上执 行的相同算子的输入、输出对比结果,以及它们是否成功通过了比较测试。

9.1.3 错误追踪与调试

如果在测试中发现错误或不一致,您可以在日志中搜索"[WARNING]" 来追踪产生 nan/inf 的位置,搜索"[ERROR]" 来追踪与 CPU 结果不一致的算子。然后,您可以调整 atol 和 rtol 的值再次尝试。或者设置 target_list 来快速重现异常算子行为,并设置 dump_error_data 来保存异常算子的输入数据:

```
from torch_musa.utils.compare_tool import CompareWithCPU
```

```
with CompareWithCPU(atol=0.001, rtol=0.001, target_list=['convolution.default'], dump_error_
data=True):
...original code...
```

这段代码将会把输入参数保存到 convolution.default_args.pkl 文件中,之后您可以用这个文件来生成单个错误用例进行调试:

```
import torch
import torch_musa
from torch_musa.utils.compare_tool import compare_single_op

compare_single_op('convolution.default_args.pkl', torch.ops.aten.convolution.default, atol=0.

$\to$0001, rtol=0.0001)
```

使用 compare_single_op 函数,您可以对特定的算子和输入进行更细致的比较和调试。



10 FAQ

10.1 设备查看问题

Q:如果在安装完驱动后,普通用户(非 root 用户)无法查看显卡,使用 sudo 权限才可以查看显卡?

将该用户添加进 render group 后即可。

1. 如果环境中已经有 render group,执行下述命令即可:

```
sudo usermod -aG render `whoami`
```

2. 如果环境中没有 render group,执行下述命令即可:

```
sudo groupadd -o -g 109 render
sudo usermod -aG render `whoami`
```

10.2 计算库无法找到

Q:如果在安装 torch_musa wheel 包后,import torch_musa 时报错无法找到 mudnn.so 库?

```
(test) → tmp python
Python 3.9.17 (main, Jul 5 2023, 20:41:20)
[GCC 11.2.0] :: Anaconda, Inc. on linux
Type "help", "copyright", "credits" or "license" for more information. >>> import torch
>>> import torch_musa
Traceback (most recent call last):
 File "/home/mt_developer/miniconda3/envs/test/lib/python3.9/site-packages/torch_musa/__init__.py", line
27, in <module>
    import torch_musa._MUSAC
ImportError: libmudnn.so.1: cannot open shared object file: No such file or directory
The above exception was the direct cause of the following exception:
Traceback (most recent call last):
 File "<stdin>", line 1, in <module>
 File "/home/mt_developer/miniconda3/envs/test/lib/python3.9/site-packages/torch_musa/__init__.py", line
29, in <module>
   raise ImportError("Please try running Python from a different directory!") from err
ImportError: Please try running Python from a different directory!
```

10. FAQ 10.3. 编译安装

1. 请确认 /usr/local/musa/lib/ 目录下是否有该库,如果没有的话,需要安装该数学库;如果有的话,需要执行:

```
export LD_LIBRARY_PATH=$LD_LIBRARY_PATH:/usr/local/musa/lib
```

10.3 编译安装

Q: 如果在更新过 torch_musa 最新代码后,编译报错?

1. 请尝试

```
python setup.py clean
bash build.sh # 整体重新编译
```

如果还报错,可能是因为需要更新 MUSA 软件栈中某个底层软件包。

10.4 Docker 容器

Q: 如果在 docker container 内部使用 torch_musa 时,报错 ImportError: libsrv_um_MUSA.so: cannot open shared object file: No such file or directory?

- 1. 请确保成功安装 mt-container-toolkit(https://mcconline.mthreads.com/software/1?id=1);
- 2. 在启动 docker container 时请添加 --env MTHREADS_VISIBLE_DEVICES=all。

10.5 适配算子

Q:如果在 CUDA-Porting 适配新算子时,编译可以通过,在 import torch; import torch_musa 时报错找不到符号?

10. FAO 10.5. 适配算子

```
[GCC 7.5.0] :: Anaconda, Inc. on Linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import torch
>>> import torch_musa
Traceback (most recent call last):
  File "/opt/conda/envs/test_environment/lib/python3.8/site-packages/torch_musa-
2.0.0-py3.8-linux-x86_64.egg/torch_musa/__init__.py", line 23, in <module>
     import torch_musa._MUSAC
ImportError: /opt/conda/envs/test_environment/lib/python3.8/site-packages/torch_
musa-2.0.0-py3.8-linux-x86 64.egg/torch musa/lib/libmusa kernels.so: undefined s
ymbol: ZN2at4musa3cub28exclusive_sum_in_common_typeIiiEEvPKT_PT0_l
The above exception was the direct cause of the following exception:
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
File "/opt/conda/envs/test_environment/lib/python3.8/site-packages/torch_musa-2.0.0-py3.8-linux-x86_64.egg/torch_musa/__init__.py", line 25, in <module> raise ImportError("Please try running Python from a different directory!") f
ImportError: Please try running Python from a different directory!
>>> exit()
(test_environment) root@77f6215babda:/home# c++filt _ZN2at4musa3cub28exclusive_s
um_in_common_typeIiiEEvPKT PT0 l
void at::musa::cub::exclusive sum in common type<int, int>(int const*, int*, lon
(test_environment) root@77f6215babda:/home# cd -
/home/torch_musa
(test environment) root@77f6215babda:/home/torch musa# vim torch musa/csrc/CMake
```

- 1. 先用 c++filt 查看符号名称
- 2. 在 PyTorch 源码中 grep 搜索这个符号:
- 如果该符号定义在 cu 文件中,那么把该 cu 文件对应的 *****.mu 文件加入到 torch_musa/csrc/CMakeList.txt中即可。
- 如果该符号定义在 cpp 文件中,那么这是一个 bug,请向 torch_musa 提交一个 issue。
- 如果 PyTorch 中也没有这个符号,那么请在 /usr/local/musa/ 中去 grep 搜索这个符号,这个符号可能是底层库定义的。
 - 如果找到这个符号,那么请检查是否没有链接这个底层库,查看命令可参考 ldd path/to/site-packages/torch_musa-2.0.0-py3.8-linux-x86_64.egg/torch_musa/lib/libmusa_kernels.so
 - 如果找到这个符号,且已经链接了对应底层库,可能底层库只暴露了这个符号,但是还未给出定义。如果是底层库暴露符号,但是 porting 的算子实际运行时没有调用符号,那么我们可以在 torch_musa 中定义一个空的实现,参考 torch_musa/csrc/aten/ops/musa/unimplemented_functions.cpp。如果底层库暴露符号,porting 的算子实际运行需要调用这个符号,那么可以给底层库提交需求。
- 3. 如果上面都没有找到上述符号,可以在 CUDA PyTorch 环境中下 grep 搜索一下,看看 CUDA 环境中 这个符号定义在哪里,再和对应 MUSA 软件模块提交需求。

10. FAO 10.6. 问题与反馈

10.6 问题与反馈

如果在开发或者使用 torch_musa 的过程中,遇到任何 bug 或者没支持的特性,请积极向 torch_musa (https://github.mthreads.com/mthreads/torch_musa/issues) 提交 issue,我们会及时作出反馈。提交 issue 时,请给出复现问题的代码,报错 log,并且打上对应的标签,如下面例子所示:

